

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第四章——决策树

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 4 章决策树, 范围为 4.1–4.4; 4.5、4.6 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】关于决策树的基本结构, 下列说法正确的是 ()。
 - A. 根结点只包含测试样本, 叶结点只包含训练样本
 - B. 每个内部结点对应一个属性测试, 叶结点对应一个预测结果
 - C. 决策树只能处理二分类问题, 不能处理多分类问题
 - D. 从根结点到叶结点的路径不包含任何判定条件
2. 【单选】在递归生成决策树时, 若当前结点中的样本全属于同一类别, 通常应当 ()。
 - A. 停止划分, 并将该结点标记为该类别
 - B. 随机选择一个未用属性继续划分
 - C. 删除该结点中的全部样本
 - D. 必须改用线性回归模型

3. 【单选】ID3 决策树在选择划分属性时，主要依据 ()。
- A. 信息增益最大 B. 信息增益率最小
- C. 基尼指数最大 D. 训练样本编号最小
4. 【单选】信息增益对某类属性存在明显偏好。为缓解这一问题，C4.5 引入的信息增益率主要惩罚的是 ()。
- A. 取值数目较多、划分过细的属性 B. 连续属性中的较小阈值
- C. 类别比例完全均衡的训练集 D. 叶结点上的多数类预测
5. 【单选】CART 决策树使用基尼指数选择划分属性时，倾向于选择 ()。
- A. 基尼指数最大的划分 B. 基尼指数最小的划分
- C. 属性取值个数最多的划分 D. 使训练样本数最少的划分
6. 【单选】关于剪枝，下列说法正确的是 ()。
- A. 剪枝的主要目的之一是缓解决策树过拟合
- B. 预剪枝一定比后剪枝得到更大的树
- C. 后剪枝不需要先生成一棵完整决策树
- D. 剪枝只能改变叶结点标记，不能改变树结构
7. 【单选】设连续属性 a 在当前结点的已排序取值为 0.2, 0.5, 0.9。二分法处理该属性时，候选划分点通常取为 ()。
- A. {0.2, 0.5, 0.9} B. {0.35, 0.70} C. {0, 1} D. {0.2, 0.9}

1.2 多选题

8. 【多选】关于决策树学习过程，下列说法正确的有 ()*。
- A. 决策树通常自根结点开始递归生成
- B. 每个需要继续划分的内部结点选择一个划分属性，将样本分配到不同分支
- C. 若当前属性集为空，通常可将结点标记为当前样本中的多数类
- D. 叶结点继续执行属性测试，内部结点直接给出类别标记
9. 【多选】关于信息熵与信息增益，下列说法正确的有 ()*。
- A. 信息熵可度量样本集合的纯度
- B. 样本越纯，信息熵通常越小
- C. 信息增益是划分前后不确定性减少的加权度量

D. 信息增益天然完全避免了对多取值属性的偏好

10. 【多选】关于信息增益率，下列说法正确的有 ()*。

- A. 它可看作信息增益除以属性的固有价值
- B. 属性划分越细，固有价值通常越大
- C. 它一定与信息增益给出完全相同的属性排序
- D. C4.5 通常先筛选信息增益不低于平均水平的属性，再比较增益率

11. 【多选】关于基尼值和基尼指数，下列说法正确的有 ()*。

- A. 基尼值越小，样本集合纯度越高
- B. 若样本集合只含一个类别，则基尼值为 0
- C. 基尼指数是划分后各子集基尼值的加权和
- D. CART 选择划分时倾向于最大化基尼指数

12. 【多选】关于预剪枝与后剪枝，下列说法正确的有 ()*。

- A. 二者都可借助验证集估计划分或剪枝后的泛化效果
- B. 预剪枝在划分前决定是否继续展开结点
- C. 后剪枝通常先生成完整树，再自底向上考察是否替换为叶结点
- D. 预剪枝完全不会带来欠拟合风险

13. 【多选】关于连续值和缺失值处理，下列说法正确的有 ()*。

- A. 连续属性可通过候选阈值转化为二分划分
- B. 连续属性在一次划分后，一定不能在后代结点再次使用
- C. 处理缺失值时，可只用该属性取值已知的样本估计划分优劣
- D. 具有缺失值的样本可按权重分配到不同分支，而不是简单丢弃

二、判断题

1. 决策树根结点通常包含训练集中的全部样本。 ()
2. 若当前结点中的样本全属于同一类别，继续划分该结点通常没有必要。 ()
3. 信息增益越大，说明使用该属性划分后样本集合纯度提升越明显。 ()
4. 信息增益不存在任何偏好，因此可直接用于所有决策树算法而无需修正。 ()
5. 基尼值为 0 表示样本集合中不存在类别混杂。 ()

6. 预剪枝通常能减少训练开销，但若过早停止划分，也可能带来欠拟合。()
7. 后剪枝先生成完整决策树，再考察是否将某些子树替换为叶结点。()
8. 采用二分法处理连续属性时，候选划分点通常来自相邻排序取值的中点。()
9. 若样本在某个属性上的取值缺失，就必须将该样本从训练集中删除。()

三、简答题

1. 简述决策树生成的递归过程，并说明哪些情形下应将当前结点标记为叶结点。
2. 比较信息增益、信息增益率和基尼指数三种划分准则。答题时应说明它们各自的选择方向及主要特点。
3. 什么是预剪枝和后剪枝？二者在过拟合控制、训练开销和欠拟合风险上有何差异？
4. 决策树如何处理连续属性和缺失属性值？请分别说明基本思路。


四、计算题

1. 当前结点中共有 10 个样本，其中正类 6 个、反类 4 个。候选属性 A 与 B 的划分结果如下：

属性	分支	正类数	反类数
A	a_1	3	1
A	a_2	2	1
A	a_3	1	2
B	b_1	5	0
B	b_2	1	4

以 $\log_2$ 为底，分别计算 A 、 B 的信息增益、信息增益率和基尼指数，并说明三种准则会选择哪个属性。计算结果保留三位小数。

2. 图中给出一棵尚未剪枝的候选树。验证集上的统计如下表，其中每一行均表示该结点被考察时，“保留子树”为保留当前子树的验证正确数，“替换为叶结点”为将该结点直接改为多数类叶结点的验证正确数。后剪枝按结点 2、结点 3、结点 1 的顺序自底向上进行；若正确数相同，则选择更简单的叶结点。




后剪枝前的候选树

结点	验证样本数	保留子树正确数	替换为叶结点正确数
2	7	5	6
3	8	7	6
1	20	16	12

判断哪些结点会被剪枝，并给出最终验证集正确率。

3. 连续属性“密度”在当前结点中的取值及类别如下表，并已按数值从小到大排列：

密度	0.20	0.35	0.40	0.55	0.75	0.90
类别	+	+	-	-	-	+



连续属性的排序取值

列出所有候选划分点，并用信息增益选择最佳二分阈值。随后考虑另一个属性 M ：在总权重为 10 的样本中， M 取值已知样本的总权重为 8，在已知样本上按 M 划分得到的信息增益为 0.250。计算考虑缺失值后的信息增益，并与属性 N 的信息增益 0.190 比较，说明应优先选择哪个属性。