

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第八章——集成学习

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 8 章集成学习, 范围为 8.1-8.5; 8.6 阅读材料不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认符号约定与课堂讲义一致。若题中另有说明, 以题中设定为准。

一、选择题

1.1 单选题

1. 【单选】关于集成学习, 下列说法最准确的是 ()。
A. 集成学习只适用于同一种学习算法生成的分类器
B. 集成学习通过结合多个学习器完成任务, 个体学习器也称基学习器
C. 只要增加个体学习器数量, 集成性能必然单调提升
D. 集成学习的核心是让所有个体学习器输出完全一致
2. 【单选】若 T 个二分类器相互独立, 且每个分类器错误率为 $\epsilon < 0.5$, 多数投票集成的错误率随 T 增大通常会 ()。
A. 逐渐下降, 理想情况下可趋近于零 B. 保持为 ϵ , 与个体数量无关
C. 逐渐上升, 因为投票会放大错误 D. 一定等于训练集上的平均错误率
3. 【单选】AdaBoost 中第 t 个基学习器的加权错误率为 ϵ_t 。在二分类设定下, 其权重通常取为 ()。
A. $\alpha_t = \epsilon_t / (1 - \epsilon_t)$ B. $\alpha_t = 1 - 2\epsilon_t$
C. $\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$ D. $\alpha_t = \ln(1 + \epsilon_t)$

4. 【单选】AdaBoost 每轮更新样本权重时, 通常会 ()。

- A. 提高被当前基学习器错分样本的权重, 降低正确分类样本的权重
- B. 删除所有被错分样本, 只保留分类正确的样本
- C. 每轮重新均匀初始化样本权重
- D. 只改变基学习器权重, 不改变训练样本权重


5. 【单选】Bagging 对包含 m 个样本的训练集进行自助采样, 采样集大小仍为 m 。当 m 较大时, 某个样本未出现在一次采样集中的概率约为 ()。

- A. 0
- B. 0.368
- C. 0.5
- D. 0.632

6. 【单选】随机森林相对于普通 Bagging 决策树的主要区别是 ()。

- A. 随机森林不使用自助采样
- B. 随机森林在训练每个结点时随机选择属性子集再划分
- C. 随机森林只能用于回归任务, 不能用于分类任务
- D. 随机森林要求所有树具有完全相同的结构

7. 【单选】图中三个基学习器给出了不同的分类边界。若它们各自具有一定准确性, 集成希望利用的主要性质是 ()。



- A. 个体学习器的错误完全相同
- B. 个体学习器之间存在适度差异, 错误可相互补偿
- C. 每个基学习器都必须是最优分类器
- D. 集成后必须保留某一个固定基学习器的边界

8. 【单选】Stacking 的核心做法是 ()。

- A. 对所有基学习器的输出直接求算术平均

- B. 用初级学习器的输出作为次级学习器的输入来训练组合模型
- C. 在每轮训练中只保留错误率最低的基学习器
- D. 将训练集随机划分为若干互不重叠的子集后分别测试

1.2 多选题

9. 【多选】关于集成学习中个体学习器的要求，下列说法正确的有 ()*。
 - A. 个体学习器应具有一定准确性，不能长期劣于随机猜测
 - B. 个体学习器之间最好完全一致，这样投票才稳定
 - C. 个体学习器之间需要有差异性，否则组合收益有限
 - D. 同质集成与异质集成的区别之一在于基学习器是否属于同一类型
10. 【多选】关于 Boosting 与 Bagging，下列说法正确的有 ()*。
 - A. Boosting 通常按序训练基学习器，后一轮会受前一轮结果影响
 - B. Bagging 的各基学习器通常可相对独立地训练，便于并行化
 - C. Boosting 主要通过重赋权或重采样关注难例
 - D. Bagging 每一轮都必须显式提高错分样本权重
11. 【多选】关于 Bagging 的包外估计，下列说法正确的有 ()*。
 - A. 包外样本可用于估计泛化误差
 - B. 包外样本是某次自助采样中未被选入训练集的样本
 - C. 包外估计完全等同于在原训练集上计算训练误差
 - D. 包外样本还可用于辅助剪枝、提前停止或特征重要性估计等操作
12. 【多选】关于结合策略，下列说法正确的有 ()*。
 - A. 回归任务中常用平均法或加权平均法
 - B. 分类任务中可使用绝对多数投票、相对多数投票或加权投票
 - C. 加权平均和加权投票通常要求权重非负，并常令权重和为 1
 - D. 学习法结合策略完全不需要训练数据

13. 【多选】设两个二分类器相对真实标记的正确、错误情况列联表为

	h_j 正确	h_j 错误
h_i 正确	a	b
h_i 错误	c	d

下列哪些量可用于度量二分类器之间的多样性或相关性 () *。

- A. 不合度量 $dis_{ij} = \frac{b+c}{m}$ B. 相关系数 $\rho_{ij} = \frac{ad-bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$
- C. Q -统计量 $Q_{ij} = \frac{ad-bc}{ad+bc}$ D. 基尼指数 $Gini(D) = 1 - \sum_k p_k^2$

14. 【多选】下列方法有助于增强集成中个体学习器多样性的有 () *。

- A. 对训练样本进行扰动，如自助采样或重采样
- B. 对输入属性进行扰动，如随机选择子空间
- C. 对输出表示进行扰动，如输出翻转或纠错输出码
- D. 固定完全相同的训练集、属性集、参数和随机种子，重复训练同一模型

二、判断题

- 若所有基学习器的预测结果完全相同，则简单投票集成与单个基学习器的预测没有本质区别。 ()
- AdaBoost 要求每个基学习器的加权错误率小于 0.5，否则对应的 α_t 不再为正。 ()
- Bagging 每轮都根据上一轮的错分样本重新调整训练样本权重。 ()
- 包外样本没有参与相应基学习器的训练，因此可用于估计该基学习器或集成的泛化性能。 ()
- 随机森林只是在 Bagging 之后对所有树做平均，没有在训练基学习器时引入额外随机性。 ()
- 相对多数投票要求某一类别获得超过半数票，否则拒绝预测。 ()
- Stacking 中次级学习器的训练输入通常由初级学习器的预测输出构成，而不是简单重复使用原始属性。 ()
- 多样性越大，集成性能就一定越好，因此个体学习器准确性并不重要。 ()

三、简答题

1. 说明集成学习中“个体学习器”“同质集成”“异质集成”“准确性”和“多样性”的含义，并解释为什么集成学习强调“好而不同”。
2. 简述 AdaBoost 的基本流程，并说明样本权重和基学习器权重各自起什么作用。
3. 比较 Bagging 与随机森林。回答时应包括自助采样、包外估计和随机属性选择三个方面。
4. 概括集成学习中的三类结合策略：平均法、投票法和学习法，并分别说明它们适合处理哪类输出。
5. 什么是集成学习中的多样性？教材中给出了哪些度量或增强多样性的思路？

四、计算题

1. 某二分类训练集有 4 个样本，标记为 $y = (+1, +1, -1, -1)$ 。AdaBoost 初始样本权重均为 $1/4$ 。第一轮基学习器 h_1 的预测为

样本	x_1	x_2	x_3	x_4
y_i	+1	+1	-1	-1
$h_1(x_i)$	+1	-1	-1	-1

第二轮基学习器 h_2 在更新后的样本权重下预测为

样本	x_1	x_2	x_3	x_4
$h_2(x_i)$	+1	+1	+1	-1

求第一轮的 ϵ_1 、 α_1 和更新后的样本权重；再求第二轮的 ϵ_2 、 α_2 ，并给出两轮后的集成分类结果 $H(x) = \text{sign}(\alpha_1 h_1(x) + \alpha_2 h_2(x))$ 。

2. 一个训练集含 $m = 10$ 个样本。Bagging 每次自助采样仍抽取 10 次，并训练一棵决策树；随机森林在每个结点从 $d = 16$ 个属性中随机选择 $k = \lfloor \log_2 d \rfloor$ 个候选属性。回答下列问题：

- (1) 某个固定样本在一次自助采样中成为包外样本的概率是多少？给出数值近似。
- (2) 一次自助采样中，训练子集包含的不同样本个数的期望是多少？
- (3) 若共训练 $T = 100$ 棵树，某个固定样本期望成为多少棵树的包外样本？
- (4) 随机森林每个结点的候选属性数 k 为多少？

3. 三个基分类器对 6 个样本的预测如下，真实标记 $y \in \{+1, -1\}$ 。设加权投票权重为 $w = (0.5, 0.3, 0.2)$ ，若加权得分为 0，则本题规定预测为 -1 。

样本	x_1	x_2	x_3	x_4	x_5	x_6
y	+1	+1	-1	-1	+1	-1
h_1	+1	+1	-1	+1	+1	-1
h_2	+1	-1	-1	-1	+1	+1
h_3	-1	+1	-1	-1	+1	-1

- (1) 给出简单多数投票的预测及其错误率。
- (2) 给出加权投票 $H(x) = \text{sign}(\sum_{t=1}^3 w_t h_t(x))$ 的预测及其错误率。
- (3) 计算 h_1 与 h_2 之间的不合度量 dis_{12} 和 Q -统计量。

密
封
线
内
不
得
答
题