

座位号:

考场号:

学号:

姓名:

题

答

得

不

内

线

封

密



《机器学习》期末考试复习样卷

第九章——聚类

中国科学技术大学 信息科学技术学院

学校: 中国科学技术大学

学院: 信息科学技术学院

学期: 26 春

课程编号: EE3502.01

授课教师: 肖力

助教: 陈璟皓 PB23010359

日期: 2026 年 6 月 18 日

时长: 2 小时

适用说明:

1. 本卷对应第 9 章聚类, 考查 9.1–9.3、9.4.1、9.5、9.6; 9.4.2、9.4.3 与 9.7 不列入考查。
2. 选择题含单选与多选, 判断题只需判断正误; 简答题重在概念准确、层次清楚, 计算题需写出关键步骤。
3. 默认距离为欧氏距离, 除非题中另有说明; 涉及集合或簇划分时, 以题中给出的符号为准。

一、选择题

1.1 单选题

1. 【单选】关于聚类任务, 下列说法最准确的是 ()。
 - A. 聚类必须先给出每个样本的类别标记
 - B. 聚类将样本划分为若干簇, 使同簇样本尽可能相似、异簇样本尽可能不同
 - C. 聚类的输出一定等同于真实类别
 - D. 聚类只能作为监督学习的最后一步
2. 【单选】若评价聚类结果时需要与某个参考模型或外部标记进行比较, 该类指标通常称为 ()。
 - A. 外部指标
 - B. 内部指标
 - C. 距离度量
 - D. 样本权重

3. 【单选】设 a 表示在聚类结果与参考划分中均属于同一簇的样本对数, b 表示在聚类结果中同簇、参考划分中不同簇的样本对数, c 表示在聚类结果中不同簇、参考划分中同簇的样本对数, d 表示在两种划分中均不同簇的样本对数。Jaccard 系数为 ()。

A. $\frac{a}{a+b+c}$ B. $\frac{a+d}{a+b+c+d}$
C. $\sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$ D. $\frac{b+c}{a+d}$

4. 【单选】关于 DB 指数与 Dunn 指数, 下列说法正确的是 ()。

- A. DB 指数越大越好, Dunn 指数越小越好
B. DB 指数越小越好, Dunn 指数越大越好
C. 二者都只适用于有参考标记的数据集
D. 二者都不依赖簇内距离和簇间距离

5. 【单选】在闵可夫斯基距离中, $p=1$ 与 $p=2$ 分别对应 ()。

- A. 欧氏距离、曼哈顿距离 B. 曼哈顿距离、欧氏距离
C. 切比雪夫距离、欧氏距离 D. 余弦距离、曼哈顿距离

6. 【单选】 k 均值算法在每一轮更新簇中心时, 通常将簇中心置为该簇样本的 ()。

- A. 均值向量 B. 最远样本 C. 任意边界点 D. 类别标记众数

7. 【单选】在 DBSCAN 中, 若样本 x 的 ε -邻域中至少包含 MinPts 个样本, 则 x 称为 ()。

- A. 噪声点 B. 边界点 C. 核心对象 D. 质心

8. 【单选】AGNES 是一种层次聚类方法, 其基本过程是 ()。

- A. 自顶向下不断拆分簇
B. 自底向上不断合并最近的簇
C. 随机初始化中心后迭代更新
D. 先训练分类器, 再给无标记样本赋类标

1.2 多选题

9. 【多选】关于聚类结果 $C = \{C_1, C_2, \dots, C_k\}$, 下列说法正确的有 ()。

- A. 不同簇通常互不相交

- B. 所有簇的并集应覆盖样本集
- C. 每个簇都必须预先对应一个已知类别名称
- D. 聚类结果可用于数据压缩、结构发现或作为后续学习的预处理

10. 【多选】关于聚类性能度量，下列说法正确的有 ()*。

- A. JC、FMI、RI 都属于外部指标
- B. DBI 和 DI 都属于内部指标
- C. RI 的取值越小表示聚类结果越好
- D. 外部指标通常需要参考划分，内部指标通常依赖簇内紧密性和簇间分离性

11. 【多选】关于距离计算，下列说法正确的有 ()*。

- A. 合法距离度量通常应满足非负性、同一性、对称性和直递性
- B. 欧氏距离与曼哈顿距离均可视为闵可夫斯基距离的特例
- C. 对离散属性，可借助 VDM 描述两个属性值之间的差异
- D. 对不同重要性的属性，可引入权重形成加权距离

12. 【多选】关于 k 均值算法，下列说法正确的有 ()*。

- A. 需要事先给定簇数 k
- B. 每轮通常包括“按最近中心分配样本”和“按当前簇更新中心”两步
- C. 不同初始中心可能导致不同聚类结果
- D. 该算法一定能找到全局最优划分

13. 【多选】关于 DBSCAN，下列说法正确的有 ()*。

- A. 需要给定邻域半径 ε 和阈值 MinPts
- B. 能把不属于任何簇的样本识别为噪声
- C. 只能发现球状簇，不能处理非凸形状
- D. 聚类结果由密度可达与密度相连关系支撑

14. 【多选】关于 AGNES 中簇间距离的定义，下列说法正确的有 ()*。

- A. 单链接使用两个簇中最近样本之间的距离
- B. 全链接使用两个簇中最远样本之间的距离
- C. 均链接使用两个簇间所有样本对距离的平均值
- D. 三种定义得到的层次结构必然完全相同

二、判断题

1. 聚类通常属于无监督学习，因为训练样本一般没有预先给定的类别标记。()
2. 外部指标的计算通常需要一个参考划分，而内部指标不需要参考划分。()
3. Dunn 指数越小越好，因为它希望簇间距离尽可能小。()
4. 只要一个函数能衡量样本之间的相似或差异，它就一定满足距离度量的全部性质。()
5. k 均值算法每轮更新后一定能得到全局最优聚类结果。()
6. DBSCAN 中的边界点不必满足核心对象条件，但可以被某个核心对象密度直达。()
7. AGNES 的凝聚式过程一旦合并两个簇，后续不会再把它们拆开。()

三、简答题

1. 说明聚类性能度量中外部指标与内部指标的区别，并各举两个例子。
2. 简述距离度量应满足的基本性质，并说明欧氏距离、曼哈顿距离和 VDM 分别适合处理什么类型的属性。
3. 写出 k 均值算法的基本步骤，并说明它的目标函数和两个常见局限。
4. 解释 DBSCAN 中 ε -邻域、核心对象、密度直达、密度可达和密度相连的含义。
5. 简述 AGNES 的基本思想，并比较单链接、全链接和均链接对簇间距离的定义。

四、计算题


1. 设样本集 $D = \{x_1, x_2, x_3, x_4, x_5, x_6\}$ 。参考划分与某算法得到的聚类结果如下：

划分	第一个簇	第二个簇
参考划分 C^*	$\{x_1, x_2, x_3\}$	$\{x_4, x_5, x_6\}$
聚类结果 C	$\{x_1, x_2, x_4\}$	$\{x_3, x_5, x_6\}$

计算 a, b, c, d ，并求 JC、FMI 和 RI。

2. 对下列二维样本运行 $k = 2$ 的 k 均值算法。初始均值向量为 $\mu_1^{(0)} = (0, 0)$ ， $\mu_2^{(0)} = (10, 10)$ ，距离采用平方欧氏距离。

样本	x_1	x_2	x_3	x_4	x_5	x_6
坐标	(0, 0)	(0, 2)	(2, 0)	(8, 8)	(8, 10)	(10, 8)



完成一次“分配-更新”迭代：给出两个簇、更新后的均值向量，并计算更新后目标函数 $E = \sum_i \sum_{x \in C_i} \|x - \mu_i\|_2^2$ 。

3. 在一维样本集

$$D = \{0, 0.4, 0.8, 3.0, 3.3, 6.0\}$$

上运行 DBSCAN，取 $\varepsilon = 0.5$ ， $\text{MinPts} = 2$ 。邻域包含样本自身，距离为普通绝对值距离。判断每个样本是否为核心对象，并给出最终簇与噪声点。